电子科技大学计算机科学与工程学院

标准实验报告

(实验)课程名称 _数据结构与算法_

电子科技大学实验报告

学生姓名: 陶浩轩 学号: 2023080902011 指导教师: 陈端兵

一、 实验室名称:

学知三组团 110139

二、实验项目名称:

频繁模式与关联规则挖掘

二、 实验原理:

FP 树通过将数据集中的频繁项集压缩成树形结构,仅存储满足最小支持度的项,从而能够高效地挖掘频繁项,因为它减少了冗余数据,并允许通过树结构快速计算项集的支持度。

四、实验目的:

通过构建频繁模式树(FP-tree),挖掘数据集中的频繁项集和关联规则,以了解项目之间的关联性。

五、实验内容:

- 1. 构建 FP-tree
- 2. 使用 FP-Growth 挖掘频繁项集

六、实验器材(设备、元器件):

Windows 10, Python 3.12.6

七、实验步骤:

1. 读取数据集:

调用 readcsv 函数,传入事务数据库的文件路径,打开 CSV 文件,逐行读取内容,将每个项目转换为整数类型,并将每个事务表示为一个元组(包含支持度计数和项目集列表),最后将所有事务存储在一个列表中并返回。

2. 初始化 FP 树:

创建 FPTree 类的一个实例,初始化根节点(其 nid 设为-1,支持度为 0),同时初始化一个空的事务数据库和头表,为构建 FP 树做准备。

3. 构建 FP 树:

调用 build 方法,传入事务数据库文件路径或已经读取的事务列表,遍历每个事务,接支持度降序处理项目集,更新 FP 树和头表,对于每个项目,如果在当前节点的子节点中已存在,则增加其支持度,否则创建新节点,并将其添加到子节点和头表中。

4. 递归增长 FP 树以挖掘频繁项集:

调用 growth 方法,传入最小支持度阈值,若最小支持度为小数,则转换为事务总数的整数比例,遍历头表中的每个项目,若其支持度大于等于最小支持度,则递归构建条件模式树,并挖掘出频繁项集。

5. 递归挖掘频繁模式:

fp_growth 方法用于递归挖掘频繁模式, 若树为单路径, 则直接提取路径中的所有组合作为频繁项集; 否则, 遍历头表中的每个项目, 构建条件模式, 并递归挖掘。

```
Procedure FP-growth (Tree, \alpha)
(1) if Tree contains a single path P
(2) then for each combination (denoted as \beta)
    of the nodes in the path P do
        generate pattern \beta \cup \alpha with support =
           minimum\ support\ of\ nodes\ in\ \beta;
(4) else for each a_i in the header of Tree do {
       generate pattern \beta = a_i \cup \alpha with
           support = a_i.support;
(6)
        construct \beta's conditional pattern base and
           then \beta's conditional FP-tree Tree_{\beta};
(7)
        if Tree_{\beta} \neq \emptyset
        then call FP-growth (Tree_{\beta},\beta)
                                                       }
(8)
```

6. 获取条件模式:

cond_pattern 方法用于获取给定节点的条件模式,通过从当前节点向上遍历至根节点,记录路径上的节点 ID,形成条件模式。

7. 打印 FP 树和头表:

print 方法用于打印 FP 树的结构,展示树中每个节点的 ID 和支持度; print header table 方法用于打印头表,显示每个项目的支持度和链接的节点。

8. 挖掘并打印最大频繁项集:

调用 mine 函数, 传入事务数据库文件路径和最小支持度, 构建 FP 树, 挖掘频繁项集, 并按支持度降序排序结果; print maximal 函数用于打印前 n 个最大频繁项集。

9. 主程序执行:

在 if __name__ == '__main__': 块中,解析命令行参数以获取文件路径和最小支持度,调用 mine 函数执行频繁模式挖掘,并打印挖掘出的频繁项集。

八、实验数据及结果分析:

使用数据集: transactional T10I4D100K.csv, 共有 100000 笔交易

可以看到,相较于实验一提供的 Apriori 算法,FP-Tree 可以在更短的时间之内完成更加巨量的数据的挖掘。

九、实验结论:

通过本次实验,我们验证了 FP-Tree 算法在频繁模式与关联规则挖掘中的有效性和高效性。实验结果表明,FP-Tree 算法不仅能够快速挖掘出频繁项集,而且能够有效地生成关联规则,为数据分析和决策提供了有力的支持

十、总结及心得体会:

在本次实验中,我深入理解了FP-Tree 算法的原理和实现过程,并通过实践操作掌握了如何使用该算法进行频繁模式挖掘。实验过程中,我体会到了数据结构算法在优化方面的重要性。高效的数据结构是提升处理效率的一大关键。

十一、对本实验过程及方法、手段的改进建议:

- 1. 可以进一步针对数据集进行数据结构方面的优化,比如针对数据的范围设定特定大小的数据类型
- 2. 在读取数据集和构建 FP 树的过程中,可以利用多线程或分布式计算来并行处理数据, 提高构建速度

3.

报告评分:

指导教师签字:

附录:源代码

FP.py

```
import csv
import sys
def readcsv(filepath: str) -> list[tuple[int, list[int]]]:
    ret = []
    with open(filepath, newline='') as csvfile:
        reader = csv.reader(csvfile, delimiter=',')
        for row in reader:
            digit = []
            for item in row:
                digit.append(int(item))
            ret.append((1, digit))
    return ret
class FPNode:
    def __init__(self, nid, support):
        self.nid = nid;
        self.support = support
        self.next = None
        self.parent = None
        self.children = {}
        self.visited = False
    def single path(self):
        size = len(self.children)
        if (size == 0): return True
        elif (size == 1): return self.first_child().single_path()
        else: return False
    def print_tree(self, level=0):
        print(' ' * level * 4 + f'Node ID: {self.nid}, Support: {self.support}')
        for child in self.children.values():
            child.print tree(level + 1)
    def first_child(self):
        children = list(self.children.values())
        if (children):
           return children[0]
        else:
            return None;
    def get_combinations(head):
        if not head:
            return [[]]
```

```
rest_combinations = FPNode.get_combinations(head.first_child())
        current combinations = [[head.nid] + combination for combination in
rest_combinations]
        return current_combinations + rest_combinations
    def find_min_support(self):
        min_sup = 1 \ll 31
        ptr = self.first child()
        while (ptr):
            if ptr.support < min_sup:</pre>
                min_sup = ptr.support
            ptr = ptr.first_child()
        return min_sup
class FPTree:
    ROOT_NID = -1
   TABLE NID = ⊘
   TABLE_SUPPORT = 1
   TABLE\_HEAD = 2
   TABLE\_TAIL = 3
    def __init__(self):
        self.root = FPNode(FPTree.ROOT NID, 0)
        self.database = []
        self.header_table = [] # [nid, support, head, tail]
    def build(self, input):
        if isinstance(input, str):
            self.build_by_db(readcsv(input))
        else:
            self.build_by_db(input)
    def build_by_db(self, db: list[tuple[int, list[int]]]):
        self.database = db
        self.N = len(db)
        header_table = {}
        for support, itemset in db:
            current node = self.root
            for nid in itemset:
                # build FP tree
                if nid in current_node.children.keys():
                    current_node.children[nid].support += support
                    header_table[nid][FPTree.TABLE_SUPPORT] += support
                else:
                    new_node = FPNode(nid, support)
                    new_node.parent = current_node
                    current_node.children[nid] = new_node
                    # build head table
                    if nid in header_table.keys():
                        header_table[nid][FPTree.TABLE_SUPPORT] += support
                        header_table[nid][FPTree.TABLE_TAIL].next = new_node
```

```
header_table[nid][FPTree.TABLE_TAIL] = new_node
                    else:
                        header_table[nid] = [nid, support, new_node, new_node]
                current node = current node.children[nid]
       self.header_table = sorted(header_table.values(), key = lambda entry :
(entry[FPTree.TABLE_SUPPORT], -entry[FPTree.TABLE_NID]))
   def growth(self, min_sup):
        if isinstance(min_sup, float):
            min_sup = int(self.N * min_sup)
            print(min_sup)
       result = []
       FPTree.fp_growth(self, [], min_sup, result)
        return result
   def fp_growth(tree, a, min_sup, result):
        if tree.root.single_path():
            combinations = FPNode.get_combinations(tree.root.first_child())
            support = tree.root.find_min_support()
            for b in combinations:
                result.append((support, a + b))
        else:
            for ai in tree.header table:
                # filter who is not frequent
                support = ai[FPTree.TABLE_SUPPORT]
                if support < min sup:</pre>
                    continue
                b = a.copy()
                b.append(ai[FPTree.TABLE_NID])
                result.append((support, b))
                # go through link list
                ptr = ai[FPTree.TABLE_HEAD]
                prefix = []
                while (ptr):
                    # get node prefix
                    cpb = FPTree.cond_pattern(ptr)
                    if (cpb):
                        prefix.append(cpb)
                    ptr = ptr.next
                if (prefix):
                    treeb = FPTree()
                    treeb.build_by_db(prefix)
                    if (treeb.root.children):
                        FPTree.fp_growth(treeb, b.copy(), min_sup, result)
   def cond_pattern(ptr: FPNode):
        prefix = []
        support = ptr.support;
        ptr = ptr.parent;
```

```
while (ptr.nid != FPTree.ROOT_NID):
            prefix.append(ptr.nid)
            ptr = ptr.parent
        return (support, prefix[::-1])
    def print(self):
        self.root.print_tree()
        print()
        self.print_header_table()
    def print_header_table(self):
        for item in self.header_table:
            print("(nid: {}, sup: {})".format(item[FPTree.TABLE_NID],
item[FPTree.TABLE_SUPPORT]), end=' ')
            ptr = item[FPTree.TABLE_HEAD]
            while (ptr) :
                print('-> (sup: {})'.format(ptr.support), end=' ')
                ptr = ptr.next;
            print()
def mine(csvfile, min_sup):
   tree = FPTree()
   tree.build(csvfile)
    result = tree.growth(min_sup)
    return sorted(result, key = lambda entry : -entry[0])
if __name__ == '__main__':
    assert len(sys.argv) >= 3
   file = sys.argv[1]
    min_support = float(sys.argv[2])
    print(mine(file, min_support))
```